

IMPATTO DELL'IA SUGLI STUDENTI

Luca Maria Incarnato N46006935

INDICE DEGLI ARGOMENTI

1. INTRODUZIONE (p. 2)
2. DESCRIZIONE DEL DATASET (p. 2)
3. METODOLOGIE E TECNICHE ADOPERATE (p. 3)
 - a. PREPROCESSING DEI DATI (p. 3)
 - b. GLI ALGORITMI ADDESTRATI (p. 4)
 - c. NAÏVE BAYES (p. 5)
 - d. DECISION TREE (p. 5)
 - e. KNN (p. 6)
 - f. METRICHE DI VALUTAZIONE (p. 7)
 - g. LA PRODUZIONE DEI DATI (p. 7)
4. RISULTATI SPERIMENTALI (p. 7)
 - a. ANALISI DEL RENDIMENTO ACCADEMICO (p. 8)
 - b. ANALISI DEL RISCHIO DI BURNOUT (p. 9)
 - c. LA CORRELAZIONE TRA LE FEATURE (p. 12)
 - d. INSIGHT E CONCLUSIONI (p. 12)

INTRODUZIONE

Il progetto in esame ha come obiettivo principale la **previsione dell'impatto dell'utilizzo degli strumenti di Intelligenza Artificiale Generativa** (ChatGPT, Copilot, Gemini, ...) **sugli studenti universitari**, analizzando il problema sotto **due punti di vista separati**: il **rendimento accademico** (performance) e il **benessere psicologico** (il rischio di burnout) degli studenti, entrambi aspetti cruciali dell'esperienza universitaria.

In aggiunta, il progetto mira a **confrontare diversi modelli di Machine Learning**, di natura completamente diversa, al fine di valutare quale paradigma logico-matematico sia più **adatto a prevedere variabili di natura oggettiva**, come i voti e le performance degli studenti, **rispetto a variabili di natura più soggettiva** e meno "quantificabile", come lo stress psicologico. A tal fine, è stata sviluppata una **pipeline di lavoro in ambiente KNIME** adatta ad implementare un Model Comparison (Benchmark) e a raccogliere i risultati in appositi file consultabili offline.

DESCRIZIONE DEL DATASET

I dati analizzati sono stati prelevati dal **dataset pubblico** ["AI Impact on Students"](#) (di [laveshjadon](#)), **scaricabile gratuitamente** e con licenza "CC0: Public Domain" dal sito web [kaggle.com](#). Il dataset si distingue per la numerosità dei dati, **50.000 record univoci e diversi tra loro**, ognuno dei quali rappresentante uno **studente universitario**, e la totale **assenza originaria di valori nulli**; tuttavia, come sarà più chiaro a breve, quest'ultima caratteristica verrà ignorata in fase di pre-processing dei dati per garantire l'estensibilità del dataset e approfondire il tema dei missing values, creando una pipeline più robusta ad eventuali cambiamenti futuri e più consapevole.

Il dataset raccoglie informazioni multidimensionali, ci sono **16 features in gioco**, in formato testuale (CSV, Comma-Separated Values) ed è raggruppabile in diverse **macro-categorie**:


- **Dati accademici**: lo storico dei voti (Pre_Semester_GPA) e la media finale (Post_Semester_GPA);
- **Abitudini di studio e Utilizzo dell'IA Generativa**: le ore settimanali di studio tradizionale (Traditional_Study_Hours), le ore di studio in cui è fatto uso di IA Generativa (Weekly_GenAI_Hours), casi d'uso principali (Primary_Use_Case) e il livello di competenza nel prompting (Prompt_Engineering_Skill);
- **Fattori psicologici e di Contesto**: il livello di dipendenza percepita dall'IA (Perceived_AI_Dependency), il livello di ansia durante gli esami (Anxiety_Level_During_Exams), la ritenzione dell'apprendimento (Skill_Retention_Score) e il rischio di esaurimento psicofisico (Burnout_Risk_Level).

Queste feature vengono affiancate ad **informazioni di contorno di natura identificativa** (Student_ID, chiave primaria dell'intero dataset) ed **accademica** (Major_Category, Year_Of_Study, Tool_Diversity, Paid_Subscription, Institutional_Policy).

Considerando l'analisi semantica effettuata sul dataset e gli obiettivi del progetto, è chiaro individuare nelle feature **Post_Semester_GPA** e **Burnout_Risk_Level** le due **feature target** per i modelli di Machine Learning della pipeline KNIME.

METODOLOGIE E TECNICHE ADOPERATE

La pipeline completa in KNIME appare come segue:



PREPROCESSING DEI DATI


In prima istanza **sono stati prelevati i dati e manipolati** affinché fossero **conformi e opportunamente organizzati** per essere ingresso dei diversi algoritmi di apprendimento e predizione. L'intera fase di preprocessing è stata **gestita nativamente tramite i nodi di KNIME** per garantire la **riproducibilità del flusso**; in particolare, sono state effettuate le seguenti operazioni:

- **Gestione dei Missing Values:** nonostante il dataset in sé e per sé non contenga missing values, al fine di realizzare un progetto future proof e quanto più robusto possibile, è stata contemplata la possibilità di un ampliamento del dataset che contenga missing values, i quali verranno gestiti tramite sostituzione al valor medio (nel caso di feature numeriche) o al valore più frequente (nel caso di feature in forma di stringa);
- **Gestione del Target:** essendo un problema di classificazione, l'unica variabile target numerica, `Post_Semester_GPA`, è stata discretizzata tramite un Numeric Binner in tre classi distinte (Low, Mid, High) sulla base dei valori di soglia 2.5 e 3.5 (Low corrisponde a $[-\infty, 2.5]$, Mid corrisponde a $[2.5, 3.5]$ e High corrisponde a $[3.5, +\infty]$);
- **Partizionamento:** il dataset è stato diviso utilizzando il nodo Table Partitioner con una ripartizione 80%-20% tra train e test set ed avvalendosi dello Stratified Sampling per preservare le proporzioni originali delle classi target;
 - Si consideri che la partizione del dataset è stata, a differenza delle operazioni di preprocessing finora introdotte, necessaria in diversi punti della pipeline. Per evitare

la spaghetizzazione del progetto, sono stati utilizzati diversi nodi Table Partitioner nei vari punti in cui erano necessari; tuttavia, per garantire suddivisioni quanto più uniformi e coerenti possibili (in modo da dare in pasto a diversi algoritmi di addestramento lo stesso train set e lo stesso test set), è stato scelto di utilizzare lo stesso seed per tutti i nodi;

Terminata la fase di preprocessing, a partire dal nodo Table Partitioner, **i due set sono stati consegnati in ingresso ai diversi algoritmi di addestramento; l'unica eccezione è stata fatta per l'algoritmo KNN**, che ha richiesto un preprocessing leggermente diverso e del quale si discuterà a breve.

Essendo il dataset in formato testuale, per l'importazione in KNIME è stato necessario inserire il nodo CSV Reader e adattare i parametri del nodo alla particolare configurazione del file.



GLI ALGORITMI ADDESTRATI

Il Benchmark è stato effettuato addestrando sullo stesso dataset per i due target (`Post_Semester_GPA`, `Burnout_Risk_Level`) tre algoritmi di Machine Learning diversi:

- **Naïve Bayes**, algoritmo probabilistico basato sull'omonimo teorema, essendo fondato sull'assunzione di totale indipendenza tra le variabili, è stato introdotto come baseline di confronto per certificare la complessità dei dati;
- **Decision tree**, algoritmo white-box basato su regole logiche (if-else) e scelto come modello principale per la sua interpretabilità visiva;
- **K-Nearest Neighbor**, o KNN, algoritmo geometrico che classifica l'istanza calcolando le distanze fisiche tra i K vicini più simili nel dataset.

La presenza delle feature di `Post_Semester_GPA` e `Burnout_Risk_Level` in ingresso ad ogni algoritmo di addestramento rende l'**apprendimento di tipo supervisionato**.

La scelta dei modelli presi in esame risiede nella **diversità delle loro caratteristiche**: seguono tre **approcci diversi** (rispettivamente, probabilistico, logico e geometrico), hanno **diversi livelli di interpretabilità e apertura** (rispettivamente, statisticamente intuibile, white-box e non visibile), **diverse modalità di apprendimento** (rispettivamente, eager learning e lazy learning, o non-instance based learning e instance based learning), le **diverse necessità nel preprocessing** (knn necessita di normalizzazione, naïve Bayes e decision tree no) e la presenza o meno di **più o meno iperparametri** (rispettivamente, nessuno, il criterio di purezza e il pre-pruning e la distanza geometrica di

osservazione). Ciò ha permesso di valutare i risultati del Benchmark sotto molteplici punti di vista, individuando una **possibile correlazione tra le caratteristiche di un modello e i punti di forza e di debolezza rilevati in questa sede**.


Di seguito saranno approfondite nel dettaglio le diverse pipeline con le quali si sono addestrati i diversi modelli per i diversi problemi, considerando che l'addestramento di un singolo modello è avvenuto due volte con due variabili target diverse.

NAÏVE BAYES

Per l'addestramento di un modello **naïve Bayes** è stato necessario utilizzare un nodo **Naïve Bayes Learning**, al cui ingresso è stato collegato il nodo corrispondente al training set del **Table Partitioner** e che è stato personalizzato per la specifica variabile target in esame; successivamente, addestrato il modello, è stata collegata la restante parte del dataset, il test set, ad un **Naïve Bayes Predictor**, al quale è stato collegato il modello in uscita dall'omonimo nodo Learner.

Le predizioni in uscita dal nodo Naïve Bayes Predictor sono state filtrate tramite un **Row Filter** per eliminare quel numero infinitesimale di istanze che il modello non è riuscito a classificare e che risulterebbero come missing values in uscita. Questi valori non vengono trattati ma la loro assenza verrà considerata per valutare il numero totale di istanze che, invece, il modello è riuscito a classificare.

Queste operazioni sono state ripetute sia per la variabile target `Post_Semester_GPA` che per `Burnout_Risk_Level`. Per questioni di visibilità e leggibilità, il blocco appena analizzato è stato astratto tramite un metanodo di KNIME, in modo che all'esterno appaia come un solo nodo la cui implementazione interna è come appena descritto.



DECISION TREE


Per l'addestramento di un modello decision tree è stato necessario utilizzare un nodo **Decision Tree Learning**, al cui ingresso è stato collegato il nodo corrispondente al training set del **Table Partitioner** e che è stato personalizzato per la specifica variabile target in esame; successivamente, addestrato il modello, è stata collegata la restante parte del dataset, il test set, ad un **Decision Tree Predictor**, al quale è stato collegato il modello in uscita dall'omonimo nodo Learner.

In fase di addestramento si è preferito **non adottare tecniche di pruning** per permettere un confronto equo tra modelli: si è preferito **sacrificare un leggero incremento di prestazioni per preferire una comparazione tra diversi modelli che sia quanto più equa e giusta possibile**.

Le predizioni in uscita dal nodo Decision Tree Predictor sono state filtrate tramite un **Row Filter** per eliminare quel numero infinitesimale di istanze che il modello non è riuscito a classificare e che risulterebbero come missing values in uscita. Questi valori non vengono trattati ma la loro assenza verrà considerata per valutare il numero totale di istanze che, invece, il modello è riuscito a classificare.

Poiché il decision tree è un modello di Machine Learning white-box, è possibile osservare **come l'algoritmo di addestramento crea l'albero decisionale** tramite un nodo **Decision Tree View**.

È possibile fare le stesse considerazioni fatte per naïve Bayes riguardo le variabili target e la leggibilità del progetto KNIME.



KNN

L'algoritmo geometrico, essendo un **algoritmo di lazy learning instance based**, non ha bisogno, come naïve Bayes o decision tree, di un nodo di addestramento e un nodo di previsione ma solo di un nodo che implementa il particolare modello (motivo per cui non sono necessari metanodi per migliorare la leggibilità del progetto KNIME). Il nodo **K Nearest Neighbor** prende in esame entrambi i set, training e test, e, sulla base del valore specificato di k , effettua l'operazione di classificazione. Il **valore di k** scelto in fase di hyperparameter tuning (tramite prove empiriche) è stato 9 per due motivi:

- Un **valore troppo basso** rende l'algoritmo troppo sensibile al rumore e **troppo alto** considera troppe istanze, perdendo i dettagli locali e andando ad agglomerare le predizioni verso la classe più numerosa, 9 è un buon compromesso;
- Un **valore dispari evita pareggi**.


Come anticipato, per addestrare l'algoritmo KNN è stata necessaria una **diversa manipolazione dei dati**; in particolare, dopo aver discretizzato la variabile target `Post_Semester_GPA` e prima del partizionamento, è stata necessaria un'operazione di **normalizzazione dei dati**. Per garantire il funzionamento dell'algoritmo geometrico KNN è stato necessario **codificare le stringhe in valori numerici** tramite il nodo **Category to Number**; successivamente, dopo aver filtrato le colonne non necessarie tramite il nodo **Column Filter**, è stato applicato un **Normalizer** (con metodo di normalizzazione Min-Max tra 0 e 1) per **uniformare la scala delle feature** ed evitare che variabili con ampio range (come le ore di studio) schiacciassero le metriche più contenute.

L'operazione di normalizzazione e filtraggio delle feature è stata fatta due volte, una per ogni variabile target; i motivi di questa scelta sono due:

- Per ogni variabile target, la **Matrice di Correlazione** (realizzata tramite il nodo **Linear Correlation** e riportata nel file `KNN_Correlation_Matrix.xlsx`) ha individuato diverse variabili più o meno correlate (a causa della diversa natura dei due problemi), il che ha reso necessario dividere il filtraggio in due;
- Per **evitare overfitting** è stato necessario escludere da ogni problema la feature relativa al problema stesso (per il problema di classificazione della performance è stata esclusa la feature `Post_Semester_GPA`, che potrebbe essere rilevante nel

problema di classificazione del rischio di burnout, e viceversa, giustificando la scelta di non fare un unico filtraggio).

La necessità di rimuovere alcune feature dall'algoritmo KNN è sorta per evitare l'incorrere della **maledizione della dimensionalità**; infatti, è stato osservato come l'inclusione di tutte le feature ha peggiorato le prestazioni dell'algoritmo, individuando empiricamente in 4 il numero di feature che ottimizza al meglio le prestazioni per entrambi i problemi.



METRICHE DI VALUTAZIONE

I **benchmark** sono stati effettuati prendendo in considerazione i **dati in uscita dai nodi Scorer**, il quale estrae dai vari modelli addestrati le relative **Matrici di Confusione**, raccolte nei file `Burnout_Confusion_Matrix.xlsx` e `GPA_Confusion_Matrix.xlsx`, per facilitare il confronto, e le relative **statistiche di accuracy**, tra cui accuratezza globale (**Accuracy**), precisione (**Precision**), sensibilità (**Recall**) e **F-Measure**, raccolti nei file `Burnout_Accuracy_Statistics.xlsx` e `GPA_Accuracy_Statistics.xlsx`, per facilitare il confronto.

LA PRODUZIONE DEI DATI

Per permettere una facile analisi dei dati prodotti dai vari modelli di Machine Learning, **in uscita da ogni modello addestrato** è stato inserito un nodo **Scorer**, che **raccoglie le predizioni e produce in uscita la matrice di confusione e l'analisi statistica dei dati** secondo le metriche precedentemente individuate. L'output in uscita dagli Scorer è stato, poi, collegato a diversi nodi **Excel Writer** in modo da **collezionare i dati in un formato facilmente fruibile**; i file Excel prodotti raggruppano i risultati dei vari modelli di Machine Learning per ogni variabile target e output dello Scorer.

RISULTATI SPERIMENTALI


Ai sensi di quanto pianificato in fase metodologica, si vogliono presentare e discutere in dettaglio le risonanze empiriche ottenute dalle pipeline di classificazione. **Il benchmark mette a confronto i tre modelli di Machine Learning selezionati** (decision tree, naïve Bayes e KNN) **applicati parallelamente alle due variabili target individuate** (`Post_Semester_GPA` e `Burnout_Risk_Level`). La valutazione quantitativa e qualitativa è stata condotta analizzando sistematicamente le rispettive **matrici di confusione** ed estraendo le metriche standard di performance predittiva: **Accuracy, Precision, Recall e F-Measure**.

ANALISI DEL RENDIMENTO ACCADEMICO


Il primo task predittivo ha riguardato il **rendimento accademico degli studenti** (relativo alla feature target `Post_Semester_GPA`, discretizzata in Low, Mid e High dopo l'operazione di binning), registrando **performance eccellenti e stabili** su tutti i modelli analizzati, confermando l'ipotesi computazionale secondo cui **le feature legate alle abitudini di studio tradizionali e al volume di utilizzo dell'Intelligenza Artificiale Generativa presentano una forte e coerente correlazione con l'output didattico oggettivo**.

Esaminando lo spaccato analitico delle metriche estratte sul Test Set (composto da 10.000 istanze complessive), emergono i seguenti comportamenti:

- **Accuratezza Complessiva (Accuracy):** naïve Bayes si è rivelato il più accurato, registrando un valore dell'86% e totalizzando il maggior numero di previsioni corrette (8.611 su 10.000). Gli altri due modelli hanno comunque garantito riscontri significativi, con KNN che si attesta all'85% (8.545 istanze corrette) e decision tree leggermente distaccato all'82% (8.212 istanze corrette);




- **Precisione (Precision):** naïve Bayes si conferma leader del comparto evidenziando un tasso estremamente ridotto di falsi positivi (81% per la classe Low, 86% per la classe Mid e 85% per la classe High), mentre KNN si posiziona su livelli analoghi (83% Low, 84% Mid e 86% High), beneficiando del preprocessing di normalizzazione. Al contrario, decision tree mostra un andamento più contratto e sottotono, in particolar modo sui segmenti critici (70% Low, 82% Mid e 83% High);




- **Sensibilità (Recall):** sul piano della capacità di intercettare correttamente le classi reali, naïve Bayes tocca un picco dell'89% sulla classe High, accompagnato dall'85% sulla Mid e dal 68%

sulla Low, mentre KNN mantiene una traiettoria speculare (66% Low, 86% Mid e 86% High) e decision tree evidenzia una marcata rigidità logica che ne limita la flessibilità (70% Low, 82% Mid e 84% High);



- **F-Measure:** nel bilanciamento armonico tra Precision e Recall, le distanze computazionali tra i modelli tendono ad assottigliarsi, KNN (74% Low, 85% Mid e 86% High) giunge quasi a sovrapporsi a naïve Bayes (74% Low, 85% Mid e 87% High), mentre decision tree riduce il gap precedentemente accumulato (70% Low, 82% Mid e 84% High).



L'aspetto indubbiamente più rilevante emerso da questo benchmark è la predominanza sistematica di **naïve Bayes**. Nonostante tale algoritmo venga comunemente introdotto come una semplice baseline a causa della sua forte assunzione di indipendenza condizionale tra le feature, **nel contesto del target GPA esso ha agito da potente regolarizzatore naturale**. Trattando le variabili in modo isolato, naïve Bayes ha evitato di perdersi nel rumore di fondo dei dati o in ramificazioni logiche iper-complesse, limitandosi a sommare i contributi probabilistici puri in modo estremamente robusto ed efficace. Ciò suggerisce che **la natura del target** (una misura oggettiva, quantificabile e prettamente deterministica) **risponda meglio a una modellazione statistico-probabilistica rispetto a logiche binarie discrete o a partizionamenti geometrici dello spazio**.


Tuttavia, l'analisi clinica delle metriche evidenzia **un'anomalia strutturale condivisa**: tutti e tre i classificatori registrano il loro **punto di cedimento in corrispondenza della classe Low** (la Recall crolla fino al 66%-68%). Tale debolezza algoritmica si traduce in un **elevato tasso di Falsi Negativi**, portando il sistema a **sovrastimare sistematicamente gli studenti a basso rendimento** inserendoli nella classe Mid. Questo pattern può essere riconducibile a due fattori principali: **uno sbilanciamento di rappresentatività campionaria** all'interno del dataset originale (che offre meno esempi storici da

cui estrarre il pattern della classe Low) o, più verosimilmente, **l'intervento di variabili esogene non campionate** (es. problematiche personali, condizioni socio-economiche o emotive) che influenzano il calo dei voti ma che sfuggono alle metriche puramente accademiche tracciate nel workflow.


ANALISI DEL RISCHIO DI BURNOUT

Il secondo task predittivo ha riguardato la predizione del livello di **stress psicofisico degli studenti** (Burnout_Risk_Level, suddiviso anch'esso in tre classi), delineando uno **scenario radicalmente opposto e intrinsecamente più complesso**. Trattandosi di un costrutto psicologico sfumato e altamente soggettivo, mappato prevalentemente attraverso feature di matrice deterministica e quantitativa, **i modelli hanno incontrato barriere strutturali nel rilevare correlazioni lineari pulite**. Le risposte degli studenti manifestano una forte componente di variabilità individuale e rumore che mal si concilia con regole analitiche rigide.


- **Accuratezza Complessiva (Accuracy):** il crollo generalizzato delle metriche globali rappresenta il primo fondamentale indicatore della complessità del task e naïve Bayes si dimostra l'unico modello capace di superare la soglia critica del 50%, registrando un'accuratezza del 51% (5.106 istanze corrette su 10.000), KNN si ferma al 47% (4.717 istanze corrette) e decision tree fa registrare la performance peggiore, scendendo al 44% (4.393 istanze corrette);




- **Precisione (Precision):** le metriche confermano una marcata tendenza alla generazione di falsi positivi, il naïve Bayes si attesta al 63% sulla classe Low, 48% sulla Mid e 48% sulla High ma il divario con gli altri algoritmi si fa netto, KNN si contrae (57% Low, 45% Mid, 44% High) e decision tree cede sensibilmente (44% Low, 43% Mid, 45% High).
 - Si annoti, come unica eccezione al trend generale, che decision tree esibisce una precisione sulla classe High (45%) leggermente superiore a quella del K-NN (44%).



- **Sensibilità (Recall):** la distribuzione del Recall sul target Burnout risulta frammentata e priva di un dominatore assoluto, riflettendo l'instabilità dei classificatori di fronte al rumore. Sulla classe Low, decision tree tocca un isolato 45% a scapito delle altre classi, sulla classe Mid, naïve Bayes si impone con un solido 69%, mentre sulla classe High è il KNN a registrare la metrica più alta con il 55%. Nonostante questi picchi isolati, i valori medi fluttuano costantemente al di sotto del 50% (naïve Bayes: 44% Low, 69% Mid, 40% High; decision tree: 45% Low, 43% Mid, 44% High; KNN: 41% Low, 41% Mid, 55% High), denunciando una produzione patologica di Falsi Negativi;



- **F-Measure:** L'andamento sintetico finale vede naïve Bayes posizionarsi lievemente sopra la media generale, agguantando un 52% sulla classe Low e un 57% sulla classe Mid, laddove il KNN risponde parzialmente solo sul segmento High (49%).



Il **parziale successo** e la **superiore resilienza** di **naïve Bayes** rispetto agli altri modelli sul target psicologico offrono uno spunto di riflessione teorica cruciale, **decision tree** è andato incontro a un evidente fenomeno di **overfitting sul training set**, nel tentativo di forzare split logici rigidi e spaccature deterministiche ("If... Then...") su un fenomeno instabile come lo stress mentale, ha costruito ramificazioni iper-specifiche che hanno fallito la generalizzazione sul test set.

Al contrario, **naïve Bayes**, fondandosi sull'assunzione di indipendenza condizionale, **ha evitato la ricerca di combinazioni e incastri logici complessi o artificiali**. Limitandosi a calcolare e sommare i pesi probabilistici isolati di ogni singola feature, ha operato un filtraggio del rumore soggettivo, dimostrandosi l'approccio matematicamente più robusto per trattare variabili qualitative debolmente correlate a feature quantitative, sebbene comunque non adatti ad un'applicazione reale.

LA CORRELAZIONE TRA LE FEATURE

Ai sensi di quanto definito in fase di preprocessing, prima di procedere all'addestramento del modello KNN è stato necessario affrontare il problema della **maledizione della dimensionalità**, che ha reso opportuna la selezione di **sole 4 feature rispetto alle 15 complessivamente a disposizione nel dataset per ogni target**; invece di procedere a una **scelta randomica degli attributi**, è stato preferito un **approccio più strutturato** basato sull'individuazione delle **feature maggiormente correlate alle due variabili target**. Oltre a stabilire il numero di dimensioni (dove il valore 4 è stato empiricamente visto essere il trade-off ideale per massimizzare le prestazioni), **l'obiettivo principale è stato isolare feature ad alto impatto sul target ma debolmente correlate tra loro**. Questo accorgimento è fondamentale per **ridurre il rumore geometrico** ed evitare **ridondanze informative** che avrebbero **deformato il calcolo delle distanze euclidee** nello spazio multidimensionale.

Per isolare questi predittori è stato necessario ricorrere allo studio della **Matrice di Correlazione**, che quantifica l'intensità del legame lineare tra le variabili all'interno di un intervallo compreso tra -1 e 1; in particolare, **la rilevanza statistica di una feature aumenta man mano che il coefficiente si allontana dallo zero centrale**, muovendosi verso gli estremi dell'intervallo, sia in senso positivo che negativo.

Per il **target di performance**, le feature più correlate sono:

1. Pre_Semester_GPA;
2. Traditional_Study_Hours;
3. Skill_Retention_Score;
4. Tool_Diversity.

Per il **target di burnout**, le feature più correlate sono:

1. Weekly_Gen_AI_Hours;
2. Perceived_AI_Dependency;
3. Anxiety_Level_During_Exams;
4. Traditional_Study_Hours.

INSIGHT E CONCLUSIONI

L'obiettivo primario del progetto (analizzare e tracciare l'impatto dell'introduzione dell'IA Generativa sulle dinamiche degli studenti universitari mediante flussi di Machine Learning) **è stato pienamente conseguito**; il benchmark comparativo ha dimostrato empiricamente che, sebbene i modelli abbiano estratto pattern statistici di indubbio valore didattico e scientifico, **sussiste una profonda linea di demarcazione in merito all'applicabilità ingegneristica reale di tali sistemi**.

I modelli sviluppati si rivelano **pronti e ottimamente configurati per una catalogazione e una previsione del rendimento accademico (GPA)**; al contrario, l'attuale impianto predittivo si dimostra strutturalmente **insufficiente per un deployment autonomo incentrato sulla diagnosi o sulla classificazione del rischio di Burnout**.

Lo scarto del 10%-15% registrato sulle metriche vitali di performance (Precision e Recall) rappresenta un vincolo non aggirabile. In uno scenario applicativo reale, un simile deficit predittivo comporterebbe implicazioni etiche e operative critiche: **l'elevato tasso di falsi negativi sul Burnout finirebbe per ignorare e privare di assistenza studenti in reale stato di crisi**, mentre **l'instabilità sulla classe Low del GPA sovrastimerebbe le performance di soggetti a rischio abbandono**; pertanto, l'insight strategico conclusivo di questo studio sancisce che tali algoritmi non devono essere

intesi come sistemi decisionali automatizzati (Human-out-of-the-loop), bensì come **architetture di Early Warning** (allerta preventiva) **a supporto dei tutor e del personale di orientamento umano.**

L'Intelligenza Artificiale funge da filtro ottimizzatore su larga scala per evidenziare macro-tendenze di vulnerabilità; spetta poi al controllo e all'empatia dell'operatore umano validare il dato e colmare quel gap analitico che i meri dati tabulari non possono, per loro natura, catturare.